

GRADO EN INGENIERÍA EN TECNOLOGÍAS DE
TELECOMUNICACIÓN

TRABAJO FIN DE GRADO

TITULO DEL TFG

Autor

Ana Arregui Beltrán

Director

Lucas Novales Peleato

Madrid

Junio 2026

Agradecimientos

Título del TFG (español)

Resumen

Título del TFG (inglés)

Abstract

Índice general

1. Introducción	13
1.1. Contexto del problema	13
1.2. Motivación	13
1.3. Problema a resolver	13
1.4. Objetivos	13
1.5. Alcance del proyecto	13
1.6. Estructura de la memoria	13
2. Fundamentos Teóricos y Tecnologías	15
2.1. Anatomía eléctrica del corazón	15
2.2. Electrocardiograma	16
2.2.1. ¿Que es un ECG?	16
2.2.2. Sistema de derivaciones del ECG	17
2.2.3. Partes del ECG	22
2.2.4. Alteraciones posibles en el ECG	25
2.3. Patologías estudiadas	26
2.4. Machine Learning	27
2.5. Clasificación multilabel	27
2.6. Métricas de evaluación	28
2.7. Tecnologías y librerías utilizadas	31
2.8. Problemas en clasificación médica - [OPCIONAL]	32
3. Estado del Arte	33
3.1. Evolución del análisis automático del ECG	33
3.2. Inteligencia artificial aplicada al ECG	34
3.3. Líneas de investigación actuales	35
3.4. Limitaciones de los enfoques actuales	36
4. Definición del Trabajo	39
4.1. Justificación del proyecto	39
4.2. Base de datos utilizada	40

4.2.1.	Origen del dataset	40
4.2.2.	Estructura del dataset	40
4.2.3.	Etiquetado original	41
4.2.4.	Problemas del dataset	41
4.3.	Agrupación de patologías	42
4.4.	Escenarios experimentales	43
4.4.1.	Configuración 1: señal reducida y clasificación binaria	43
4.4.2.	Configuración 2: señal completa y clasificación binaria	43
4.4.3.	Configuración 3: señal completa y clasificación multilabel probabilística	43
4.5.	Objetivos técnicos	44
4.6.	Metodología general	45
5.	Modelo Desarrollado	47
5.1.	Arquitectura general del sistema	47
5.2.	Análisis exploratorio de datos	48
5.3.	Preprocesado de datos	54
5.4.	Selección y extracción de características	54
5.5.	Desarrollo experimental y optimización del sistema	54
6.	Análisis de Resultados	55
7.	Conclusiones y Trabajos Futuros	57
	Bibliografía	59

Índice de figuras

2.1. Anatomía eléctrica del corazón.	16
2.2. Triángulo de Einthoven.	18
2.3. Eje de las derivaciones bipolares en el plano frontal	19
2.4. Eje de las derivaciones aumentadas de las extremidades en el plano frontal	20
2.5. Sistema hexaxial	20
2.6. Derivaciones precordiales.[poner pie de pagina con la fuente]	22
2.7. Esquema de un ciclo cardíaco típico del ECG	25
2.8. Matriz de confusión.	29
5.1. Pipeline general del sistema. Elaboración propia.	48
5.2. Distribución de los pacientes por edad	49
5.3. Distribución de los pacientes por sexo	49
5.4. Distribución de los pacientes por edad y sexo	50
5.5. Distribución de las patologías en el conjunto de datos.	50
5.6. Distribución de las patologías más frecuentes en el conjunto de datos.	51
5.7. Distribución de las patologías por superclases.	51
5.8. Matriz de co-ocurrencia de las 20 clases más frecuentes.	52
5.9. Distribución del número de patologías por paciente.	53

Índice de tablas

2.1. Interpretación del eje cardíaco según las derivaciones DI y aVF (Prutkin et al., 2025)	21
--	----

Capítulo 1

Introducción

1.1. Contexto del problema

1.2. Motivación

1.3. Problema a resolver

1.4. Objetivos

1.5. Alcance del proyecto

Que hace, que no hace y limitaciones

1.6. Estructura de la memoria

Capítulo 2

Fundamentos Teóricos y Tecnologías

2.1. Anatomía eléctrica del corazón

El corazón es un órgano muscular que funciona como una bomba para impulsar la sangre a través del sistema circulatorio. Esta acción de bombeo está regulada por un sistema eléctrico, encargado de coordinar las contracciones de las distintas cavidades del corazón.

El latido se genera en la aurícula derecha, donde se encuentra el nodo sinoauricular (SA) que actúa como marcapasos natural del corazón. El nodo SA envía pulsos eléctricos que se propagan a través de las aurículas derecha e izquierda, llegando al nodo auriculoventricular (AV). En este nodo, el impulso disminuye brevemente, permitiendo que las aurículas se contraigan antes que los ventrículos. Así, la sangre se vacía de la aurículas a los ventrículos antes de su contracción.

Después de pasar por el nodo AV, la corriente eléctrica desciende por el Haz de His hasta los ventrículos. Esta vía se divide en dos ramas, derecha e izquierda, conocidas como ramas de His. Estas ramas estimulan eléctricamente los ventrículos derecho e izquierdo, provocando su contracción y el bombeo de la sangre hacia el exterior del corazón. (Stanford Children's Health, s.f.-a)




Figura 2.1: Anatomía eléctrica del corazón.

1

[Explicar la anatomía básica del corazón??]

2.2. Electrocardiograma

2.2.1. ¿Que es un ECG?

El electrocardiograma (ECG) es la representación gráfica de la actividad eléctrica del corazón a lo largo del tiempo. Se trata de una prueba no invasiva, de bajo coste y fácil de realizar. Esta representación se utiliza para buscar actividad cardíaca anormal, que pueda indicar la presencia de patologías cardíacas.

No solo se utiliza para diagnosticar enfermedades, sino que el ECG puede evaluar el ritmo cardíaco, si este es regular o irregular y la fuerza y sincronización de las señales eléctricas. Además, se puede medir el tamaño y la posición de las cavidades del corazón. (MedlinePlus, s.f.)

El ECG es una herramienta fundamental en la práctica clínica, ya que permite la interpretación del ritmo cardíaco y la detección de alteraciones del sistema eléctrico. Aporta información relevante en la evaluación de patologías cardiovasculares, como valvulopatías, miocardiopatías, pericarditis, isquemia miocárdica o enfermedades hipertensivas. Por otro lado, el ECG se puede utilizar para monitorizar la respuesta a tratamientos farmacológicos, especialmente antiarrítmicos, así como en la detección de alteraciones metabólicas. (Prutkin et al., 2025)

¹Cigna, s.f.

2.2.2. Sistema de derivaciones del ECG

Para medir la actividad eléctrica del corazón, se colocan electrodos en cada una de las extremidades y en el pecho, formando un sistema de 12 derivaciones. Cada derivación mide la diferencia de potencial eléctrico entre dos puntos o un punto del cuerpo y una referencia. El electrodo conectado en la pierna derecha sirve como electrodo de referencia a tierra. (Klabunde, Richard E., 2023)

Existen dos tipos de derivaciones: las derivaciones bipolares y las derivaciones unipolares. Las derivaciones bipolares utiliza un electrodo positivo y otro negativo para medir la diferencia de potencial, mientras que las derivaciones unipolares utilizan un unico electrodo positivo y una combinación de otros electrodos como electrodo de referencia.

Las doce derivaciones se agrupan en tres categorías según su ubicación: las derivaciones de las extremidades (I, II, III), las derivaciones aumentadas de las extremidades (aVR, aVL, aVF) y las derivaciones precordiales (V1-V6).

■ Derivaciones de las extremidades

Son las únicas derivaciones bipolares y se colocan en brazos y piernas. Miden la actividad eléctrica del corazón en el plano frontal.

- Derivación I: Tiene el electrodo positivo en el brazo izquierdo y el negativo en el brazo derecho, midiendo la diferencia de potencial entre ambos brazos.
- Derivación II: Tiene el electrodo positivo en la pierna izquierda y el negativo en el brazo derecho, midiendo la diferencia de potencial entre ambos puntos.
- Derivación III: Tiene el electrodo positivo en la pierna izquierda y el negativo en el brazo izquierdo, midiendo la diferencia de potencial entre ambos puntos.

Estas tres derivaciones forman un triángulo equilátero, conocido como el *triángulo de Einthoven*, que representa la relación entre las derivaciones de las extremidades. Esta relación es tal que la suma de los impulsos eléctricos registrados en las derivaciones I y III es equivalente a la suma de los impulsos registrados en la derivación II:

$$DII = DI + DIII$$

Esta ley se conoce como *Ley de Einthoven* y constituye una base fundamental para la interpretación vectorial de la actividad eléctrica cardíaca y permite verificar la coherencia de las señales registradas. (My-EKG, s.f.-a)




Figura 2.2: Triángulo de Einthoven.

■ Derivaciones aumentadas de las extremidades

Se trata de derivaciones unipolares, que utilizan como referencia, una combinación de los electrodos de las extremidades. Al igual que estas, analizan la actividad eléctrica del corazón en el plano frontal.

- Derivación aVR: El electrodo positivo está en el brazo derecho y mide la diferencia de potencial entre el brazo derecho y el centro del corazón.
- Derivación aVL: El electrodo positivo está en el brazo izquierdo y mide la diferencia de potencial entre el brazo izquierdo y el centro del corazón.
- Derivación aVF: El electrodo positivo está en la pierna izquierda y mide la diferencia de potencial entre la pierna izquierda y el centro del corazón.

Estas derivaciones, complementan a las bipolares y permiten una visión más completa del plano frontal del corazón.

Sistema hexaxial y eje del corazón

Si el triángulo de Einthoven se despliega y se superpone sobre el centro cardíaco, se puede definir un sistema de referencia angular que permite definir la dirección de la actividad eléctrica del plano frontal.

Como se observa en la Figura 2.3 cada derivación bipolar tiene una orientación espacial:

- La derivación I se sitúa a 0° , correspondiente al eje horizontal entre el brazo derecho y el brazo izquierdo.

- La derivación II tiene una orientación aproximada de $+60^{\circ}$ con respecto a este eje horizontal, entre el brazo derecho y la pierna izquierda.
- La derivación III se orienta a $+120^{\circ}$, entre el brazo izquierdo y la pierna izquierda.

Estas direcciones permiten interpretar la actividad eléctrica cardíaca como la proyección de un vector sobre distintos ejes espaciales. De este modo, el electrocardiograma no solo representa amplitudes eléctricas, sino también información direccional de la despolarización cardíaca.




Figura 2.3: Eje de las derivaciones bipolares en el plano frontal

A partir de este sistema de derivaciones se incorporan las derivaciones aumentadas de las extremidades, que completan la cobertura del plano frontal y permiten una explicación más precisa del vector eléctrico. Estas derivaciones se sitúan en los siguiente ángulos:

- Derivación aVL: -30° sobre la horizontal
- Derivación aVR: -150° sobre el eje horizontal
- Derivación aVF: $+90^{\circ}$ sobre el plano horizontal




Figura 2.4: Eje de las derivaciones aumentadas de las extremidades en el plano frontal

El conjunto de estas seis derivaciones constituye el sistema hexaxial completo, que permite analizar la dirección del vector eléctrico cardíaco en el plano frontal y constituye la base para la determinación del eje eléctrico del corazón.




Figura 2.5: Sistema hexaxial

Este eje se determina a partir del complejo QRS (ver apartado 2.2.3), que representa la suma vectorial de todos los vectores eléctricos generados por la despolarización ventricular. Analizando la polaridad del QRS en las derivaciones del plano frontal, es posible determinar la dirección estimada de la actividad eléctrica cardíaca. En la práctica clínica, las derivaciones I y aVF son las más utilizadas para hacer una estimación rápida del eje eléctrico.

La determinación del eje se basa en la polaridad del complejo QRS en estas derivaciones. Cuando el vector de despolarización se dirige hacia el polo positivo de una derivación, la deflexión del complejo QRS es positiva; por el contrario, si el vector se aleja, la deflexión es negativa. (“Eje cardíaco en el ECG: cálculo e interpretación”, 2026)

El eje cardíaco en condiciones normales se encuentra entre -30° y 90° , haciendo que el vector resultante apunte abajo y a la izquierda. En este caso,

el complejo QRS es positivo tanto en DI como en aVF.

En la tabla 2.1 se resume la interpretación del eje cardíaco en función de la polaridad del complejo QRS en las derivaciones I y aVF.

Tabla 2.1: Interpretación del eje cardíaco según las derivaciones DI y aVF (Prutkin et al., 2025)

DI	aVF	Cuadrante	Rango del eje	Interpretación
+	+	Inferior izquierdo	-30° a $+90^\circ$	Eje normal
+	-	Superior izquierdo	-30° a -90°	Desviación izquierda del eje
-	+	Inferior derecho	$+90^\circ$ a $+180^\circ$	Desviación derecha del eje
-	-	Superior derecho	-90° a -180°	Eje extremo derecho o izquierdo

■ Derivaciones precordiales

Estas seis derivaciones unipolares se colocan en el pecho, en diferentes regiones del corazón, y miden la actividad eléctrica en un plano perpendicular al plano frontal. Cada una de las derivaciones precordiales observa una región específica del ventrículo.

- Derivaciones V1-V2: Exploran la región septal y anteroseptal del corazón, observando principalmente el septo interventricular.
- Derivaciones V3-V4: Exploran la región anterior del corazón y el apex cardíaco, observando principalmente la pared anterior del ventrículo izquierdo.
- Derivaciones V5-V6: Exploran en la región lateral y anterolateral izquierda del corazón, observando principalmente la pared lateral del ventrículo izquierdo.




Figura 2.6: Derivaciones precordiales.[poner pie de pagina con la fuente]

2.2.3. Partes del ECG

Un ciclo cardíaco típico en el ECG está compuesto por varias ondas y segmentos característicos, cada uno de los cuales se asocia a una fase concreta del proceso eléctrico del corazón. En la Figura 2.7 se muestra un esquema completo de un ciclo cardíaco típico.

Onda P

La onda P representa la despolarización de las aurículas. Morfológicamente, presenta una onda suave y amplitud baja, siendo positiva en la mayoría de las derivaciones, salvo en aVR.

La aurícula derecha se despolariza primero, seguida de la aurícula izquierda, por lo que esta onda puede presentar una muesca en algunas derivaciones de las extremidades, o ser bifásica en V1. En esta derivación, la parte inicial de la onda P corresponde a la despolarización de la aurícula derecha, mientras que la parte final corresponde a la aurícula izquierda.

La repolarización auricular ocurre simultáneamente a la despolarización ventricular, por lo que lo que suele quedar oculta por el complejo QRS, por lo que no suele ser visible.

Intervalo PR

El intervalo PR representa el tiempo total que transcurre desde el inicio de la despolarización auricular hasta el inicio de la despolarización ventricular. Incluye tanto la onda P como el segmento PR.

Se mide desde el inicio de la onda P hasta el inicio del complejo QRS. En condiciones normales, su duración puede variar en función de la frecuencia cardíaca, ya que a frecuencias elevadas se produce una aceleración de la conducción a través del nodo AV, lo que reduce el intervalo PR. Por el contrario, a frecuencias bajas la conducción se enlentece, alargando el intervalo PR.

Una alteración en la duración del intervalo PR puede indicar bloqueos o cambios en la velocidad de conducción del impulso eléctrico. Un intervalo PR prolongado puede indicar un bloqueo AV de primer grado, y un intervalo PR corto puede indicar la existencia de una vía de conducción adicional, como en el síndrome de Wolff-Parkinson-White.

Complejo QRS

El complejo QRS representa la despolarización ventricular, que es el proceso eléctrico más potente del corazón. Su análisis es fundamental para la interpretación del ECG, ya que proporciona información sobre la conducción eléctrica ventricular, el tamaño y la posición de los ventrículos, así como la presencia de bloqueos o alteraciones en la conducción.

Es una onda de corta duración, que indica que la despolarización ventricular es un proceso rápido. Una larga duración del QRS puede indicar alteraciones en la conducción, como bloques de rama o ritmos originados fuera del sistema de conducción normal.

El complejo QRS está compuesto por las siguientes deflexiones:

- **Onda Q:** Es la primera deflexión negativa del complejo QRS, que representa la despolarización del septo interventricular. En condiciones normales, esta onda es pequeña y estrecha, y puede no ser visible en todas las derivaciones.
- **Onda R:** Es la primera deflexión positiva del complejo QRS, que representa la despolarización del ventrículo izquierdo. Es la onda más alta del complejo QRS y su amplitud varía según la derivación.
- **Onda S:** Es la segunda deflexión negativa del complejo QRS, que representa las fases finales de la despolarización ventricular.
- **Onda R':** Es una segunda deflexión positiva que puede aparecer después de la onda S.

Segmento ST

El segmento ST es la porción del ECG que se encuentra entre el final del complejo QRS y el inicio de la onda T. Representa el período en el que los ventrículos

están completamente despolarizados, es decir, el tiempo entre la despolarización y la repolarización ventricular.

El punto de unión entre el complejo QRS y el segmento ST se conoce como el punto J. En condiciones normales, el segmento ST es isoelectrico, es decir, se encuentra al mismo nivel que la línea de base del ECG. Sin embargo, en ciertas patologías, como la isquemia miocárdica o el infarto de miocardio, el segmento ST puede presentar elevación o depresión, lo que indica un proceso patológico en el corazón.

En condiciones normales también pueden observarse ligeras variaciones fisiológicas del segmento ST, especialmente durante episodios de taquicardia sinusal, donde el punto J puede encontrarse discretamente deprimido acompañado de un ascenso rápido del segmento ST hasta recuperar la línea isoelectrica.

Onda T

La onda T representa la repolarización ventricular, que es el proceso eléctrico mediante el cual los ventrículos recuperan su estado de reposo después de la contracción. Es una onda de baja amplitud y duración más larga que el complejo QRS.

En condiciones normales, la onda T suele ser asimétrica, con una ascensión más lenta y una bajada más rápida hacia la línea isoelectrica. Suele ser una onda de amplitud baja y una forma suave. La presencia de muescas, irregularidades o deformaciones puede sugerir la superposición de otras ondas, como la onda P.

Intervalo QT

El intervalo QT representa el tiempo total de actividad eléctrica ventricular. Incluye tanto la despolarización como la repolarización ventricular, desde el inicio del complejo QRS hasta el final de la onda T.

Depende de la frecuencia cardíaca, siendo más corto a frecuencias elevadas y más largo a frecuencias bajas.

Para poder compararlo entre distintos registros con diferentes frecuencias cardíacas, se utiliza el intervalo QT corregido (QTc), que ajusta su valor en función del intervalo RR.

La prolongación del intervalo QT puede asociarse a un mayor riesgo de arritmias ventriculares, por lo que constituye un parámetro de relevancia clínica en la interpretación del ECG.

Onda U

La onda U (no visible en la Figura 2.7) es una pequeña deflexión que puede aparecer en el electrocardiograma después de la onda T. Puede hacerse más eviden-

te en ciertas situaciones, como la hipopotasemia o la bradicardia. La presencia de ondas U prominentes o alteraciones en su morfología puede estar asociada a cambios en la repolarización ventricular y, en algunos casos, a condiciones patológicas subyacentes




Figura 2.7: Esquema de un ciclo cardíaco típico del ECG

2.2.4. Alteraciones posibles en el ECG

Las alteraciones del electrocardiograma corresponden a desviaciones del patrón eléctrico normal, que puede indicar anomalías en la generación del impulso, su propagación o la repolarización del miocardio. Constituyen la base de la interpretación clínica del ECG, permitiendo identificar distintos tipos de patologías a partir del cambio en el ritmo, la conducción o la forma de la señal.

Alteraciones del ritmo cardíaco

Se producen cuando se modifica la generación normal del impulso eléctrico. En condiciones normales, el nodo SA actúa como marcapasos natural, estableciendo un ritmo regular.

Si este mecanismo falla, aparecen las arritmias, que pueden manifestarse como cambios en la frecuencia o en la regularidad del ritmo. Las más comunes son la bradicardia (frecuencia cardíaca baja), la taquicardia (frecuencia cardíaca alta) y ritmos irregulares, como la fibrilación auricular.

Alteraciones de la conducción eléctrica

Aparecen cuando existe un retraso o bloqueo en la propagación del impulso eléctrico a través del sistema de conducción cardíaco.

Pueden localizarse a nivel del nodo AV o del sistema His-Purkinje. Entre las principales se incluyen los bloqueos auriculoventriculares y los bloqueos de rama,

que se caracterizan por una prolongación del complejo QRS y alteraciones en su morfología.

Alteraciones morfológicas del ECG

Corresponden a cambios en la forma de las ondas, segmentos o intervalos del ECG.

Destacan las alteraciones del segmento ST, que pueden aparecer elevado o deprimido y se asocian frecuentemente a procesos isquémicos. También es relevante la inversión de la onda T, relacionada con alteraciones en la repolarización ventricular, así como las modificaciones del intervalo QT, que pueden indicar cambios en la duración global de la actividad eléctrica ventricular.

2.3. Patologías estudiadas

Las alteraciones detectadas en el ECG pueden afectar a la generación, propagación o recuperación del impulso eléctrico, reflejándose en cambios característicos en la señal.

Entre las principales categorías clínicas relevantes en el análisis del ECG se encuentran distintas patologías que afectan a la morfología de las ondas, los intervalos y la conducción cardíaca.

A continuación, se describen las más representativas en el contexto de este estudio:

- Normal (NORM)

Esta clase son electrocardiogramas sin alteraciones y que representan el patrón fisiológico de referencia. La actividad eléctrica del corazón en estos casos sigue una secuencia normal de generación y propagación del impulso.

- Infarto de miocardio (MI)

Agrupar patologías relacionadas con el daño del tejido miocárdico. Se reflejan principalmente en cambios en el segmento ST y en la onda T, así como en modificaciones de la morfología general del electrocardiograma.

- Bloqueos de conducción (CD)

Incluye alteraciones en la propagación del impulso eléctrico a través del sistema de conducción cardíaco. Pueden afectar a la sincronización entre aurículas y ventrículos o a la activación ventricular, reflejándose en cambios en los intervalos y en el complejo QRS.

- Alteraciones ST-T (STTC)

Engloba alteraciones en la repolarización ventricular. Se manifiesta mediante cambios en el segmento ST y en la onda T y suele estar asociada a procesos isquémicos o alteraciones en la actividad eléctrica del miocardio.

- Hipertrofia (HYP)

Incluye alteraciones derivadas de cambios estructurales del corazón, como el aumento del grosor de las paredes cardíacas. Estas modificaciones afectan a la propagación del impulso eléctrico y se reflejan en cambios en la amplitud y morfología de la señal ECG.

2.4. Machine Learning

“El Machine Learning es una rama de la inteligencia artificial que hace posible el aprendizaje autónomo de las máquinas, sin necesidad de ser programadas expresamente para cada tarea. Su objetivo principal es desarrollar algoritmos y modelos capaces de analizar grandes volúmenes de datos, detectar patrones y aprender de ellos.” (Repsol, 2026)

Dentro del aprendizaje automático, el enfoque más común en problemas biomédicos es el aprendizaje supervisado, en el que el modelo se entrena utilizando un conjunto de datos etiquetados. Así, el sistema aprende una relación entre las características de entrada y la salida esperada.

Estos problemas pueden ser de clasificación, donde el objetivo es asignar una etiqueta a cada muestra o de regresión, donde se predice un valor continuo. La clasificación puede ser binaria, cuando solo hay dos clases posibles, o multiclase, cuando existen más de dos clases. En el caso de la clasificación multilabel, cada muestra puede pertenecer a varias clases simultáneamente, como es el caso de este proyecto.

2.5. Clasificación multilabel

La clasificación multilabel es un problema de aprendizaje supervisado en el que cada muestra puede pertenecer a múltiples clases simultáneamente.

Este enfoque es especialmente relevante en el ámbito médico, ya que un mismo paciente puede presentar varias patologías al mismo tiempo. En el caso de los electrocardiogramas, es posible observar alteraciones simultáneas en una misma señal.

En este contexto, las etiquetas suelen representarse mediante vectores binarios, donde cada posición indica la presencia o ausencia de una clase específica. Este

tipo de representación permite modelar de forma sencilla la existencia de múltiples patologías en un mismo registro.

2.6. Métricas de evaluación

La evaluación de modelos de clasificación se realiza mediante diferentes métricas que permiten cuantificar su rendimiento desde distintas perspectivas. En problemas médicos, estas métricas resultan especialmente relevantes, ya que no solo interesa la exactitud global del modelo, sino también su capacidad para detectar correctamente cada patología.

Matriz de confusión

Es un método de visualización para los resultados de clasificación. Es la base de la mayoría de métricas de evaluación. (Murel y Kavlakoglu, s.f.) Permite comparar las predicciones del modelo con las etiquetas reales y se define en términos de:

- **Verdaderos Positivos (TP):** Número de muestras correctamente clasificadas como positivas.
- **Falsos Positivos (FP):** Número de muestras incorrectamente clasificadas como positivas.
- **Verdaderos Negativos (TN):** Número de muestras correctamente clasificadas como negativas.
- **Falsos Negativos (FN):** Número de muestras incorrectamente clasificadas como negativas.

En la Figura 2.8 se muestra la estructura general de una matriz de confusión para un problema de clasificación binaria. En problemas multilabel, se puede construir una matriz de confusión para cada clase. Esta matriz es fundamental para calcular otras métricas de evaluación, como la precisión, la sensibilidad o el F1-score, que se definen a partir de los valores de TP, FP, TN y FN.

		PREDICTIVE VALUES	
		POSITIVE	NEGATIVE
ACTUAL VALUES	POSITIVE	TP	FN
	NEGATIVE	FP	TN

Figura 2.8: Matriz de confusión.

Accuracy

La exactitud o accuracy es una métrica de evaluación que mide la proporción de predicciones correctas realizadas por el modelo, respecto al total de muestras evaluadas. (Evidently AI, 2025) Se calcula utilizando la siguiente fórmula:

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}$$

Esta métrica proporciona una visión global del rendimiento del modelo, indicando con qué frecuencia el sistema clasifica correctamente las muestras. Sin embargo, en problemas con clases desbalanceadas o en problemas multilabel, la accuracy puede ser poco representativa, ya que no refleja adecuadamente el rendimiento en cada clase. (Murel y Kavlakoglu, s.f.)

Precision

La precisión o precision es una métrica que mide la proporción de predicciones positivas que son correctas. Indica que porcentaje de los casos clasificados como positivos por el modelo realmente pertenecen a la clase positiva. Se calcula como:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Esta métrica permite evaluar la fiabilidad de las predicciones positivas del modelo. (Evidently AI, 2025) En un contexto médico, una baja precisión implica un aumento de los falsos positivos, lo que puede llevar a diagnósticos erróneos o a la realización de pruebas innecesarias. Sin embargo, resulta es más relevante en problemas donde el costo de los falsos positivos es alto, como en el diagnóstico de

enfermedades graves. [\[Revisar esto. No me convence como está escrito\]](#) En problemas multilabel, la precisión se puede calcular para cada clase de forma individual, lo que permite evaluar el rendimiento del modelo en cada patología específica.

Recall

El recall o sensibilidad es una métrica que mide la capacidad del modelo para identificar correctamente los casos positivos reales. Indica que proporción de las muestras que pertenecen a una clase son efectivamente detectadas por el modelo. (Evidently AI, 2025) Se define como:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Esta métrica es especialmente relevante en el ámbito médico, ya que una baja sensibilidad implica un aumento de los falsos negativos, es decir, casos en los que una patología existente no es detectada por el modelo. Por esto, se considera una métrica crítica cuando el objetivo es minimizar el riesgo de no identificar enfermedades.

F1-score

El F1-score es una métrica que combina la precisión y el recall en un único valor, proporcionando una medida equilibrada del rendimiento del modelo. (Buhl, 2023) Se calcula como la media armónica de la precisión y el recall:

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Esta métrica es especialmente útil en problemas con clases desbalanceadas, ya que penaliza de forma significativa los casos en los que una de las dos métricas es baja. En un contexto médico, el F1-score permite evaluar de manera más equilibrada el rendimiento del modelo cuando es importante minimizar tanto los falsos positivos como los falsos negativos.

Hamming Loss y Hamming Accuracy

En problemas de clasificación multilabel, cada muestra puede pertenecer a varias clases simultáneamente, lo que hace necesario utilizar métricas específicas para evaluar el rendimiento del modelo en este contexto.

El Hamming Loss es una métrica que mide la proporción de etiquetas incorrectamente predichas por el modelo respecto al total de etiquetas evaluadas. (Amit,

2024) Se define como:

$$\text{Hamming Loss} = \frac{1}{N \cdot L} \sum_{i=1}^N \sum_{j=1}^L \mathbb{I}(y_{ij} \neq \hat{y}_{ij})$$

donde N es el número de muestras, L es el número de clases, y_{ij} es la etiqueta real de la muestra i para la clase j , $\hat{y}_{ij}$ es la etiqueta predicha por el modelo, y $\mathbb{I}$ es la función indicadora que devuelve 1 si las etiquetas son diferentes y 0 si son iguales.

Un valor de Hamming Loss cercano a 0 indica un buen rendimiento del modelo ya que implica un menor número de errores a nivel de etiqueta individual.

De forma complementaria, el Hamming Accuracy se define como la proporción de etiquetas correctamente clasificadas respecto al total.

$$\text{Hamming Accuracy} = 1 - \text{Hamming Loss}$$

Es especialmente útil en problemas multilabel, ya que evalúa el rendimiento del modelo considerando cada etiqueta de forma individual, en lugar de considerar únicamente la predicción global de cada muestra.

2.7. Tecnologías y librerías utilizadas

En este trabajo se ha empleado principalmente Python como lenguaje de programación, debido a su amplio número de librerías orientadas al análisis de datos, el procesamiento de señales y el desarrollo de modelos de Machine Learning.

En el procesamiento y manipulación de datos se han utilizado las librerías Pandas y NumPy. NumPy ha permitido trabajar con arrays multidimensionales de forma eficiente, mientras que Pandas ha facilitado la gestión de datos tabulares, permitiendo realizar operaciones de limpieza, transformación y análisis de manera sencilla, especialmente en lo relativo a las etiquetas y características de los pacientes.

Para el procesamiento de señales y análisis de señales se ha empleado SciPy, que proporciona herramientas específicas para el tratamiento de señales digitales, siendo especialmente relevante en el contexto de electrocardiogramas.

Por otro lado, la lectura y manipulación de los registros de electrocardiogramas se ha realizado mediante la librería WFDB, muy utilizada en el ámbito biomédico para el manejo de bases de datos de señales fisiológicas.

La implementación y validación de los modelos de aprendizaje automático se ha llevado a cabo utilizando Scikit-learn, que incluye una amplia variedad de algoritmos de clasificación, así como herramientas para la evaluación del rendimiento de los modelos y la validación de los resultados.

Finalmente, para la visualización de datos y la creación de una interfaz interactiva se han utilizado la librerías Matplotlib, Dash y Plotly, que permiten generar gráficos y visualizaciones dinámicas, facilitando la interpretación de los resultados y la exploración de los datos. [\[Revisar esto, porque ha día 24 de mayo está sin hacer el dashboard\]](#)

2.8. Problemas en clasificación médica - **[OPCIONAL]**

Capítulo 3

Estado del Arte

Las enfermedades cardiovasculares son un de las principales causas de mortalidad en el mundo, lo que ha impulsado el desarrollo de herramientas de diagnóstico capaces de detectar estas patologías de manera temprana y precisa. Entre estas herramientas, el electrocardiograma (ECG) se destaca como una técnica no invasiva, rápida y ampliamente disponible para evaluar la actividad eléctrica del corazón.

La interpretación del ECG es una herramienta fundamental en el diagnóstico de un gran número de enfermedades cardiovasculares. Tradicionalmente, este proceso ha sido realizado por especialistas médicos de forma manual mediante la inspección visual de la señal, lo que requiere experiencia clínica y puede verse afectado por la subjetividad del observador o la variabilidad entre especialistas. Además, el aumento del volumen de datos clínicos generados en hospitales y sistemas de monitorización hace cada vez más complejo el análisis manual de grandes cantidades de registros electrocardiográficos.

En este contexto, la inteligencia artificial (IA) y las técnicas de aprendizaje automático han adquirido un papel cada vez más relevante en el ámbito del diagnóstico médico, ofreciendo la posibilidad de automatizar la interpretación del ECG y mejorar la precisión diagnóstica. Estos sistemas buscan ser herramientas de apoyo al diagnóstico, facilitando una interpretación más rápida y consistente de los registros electrocardiográficos, así como la detección de patrones sutiles que podrían pasar desapercibidos para el ojo humano.

3.1. Evolución del análisis automático del ECG

Los primeros enfoques para el análisis automático del ECG se basaban en técnicas de procesamiento de señales y extracción manual de características relevantes, como la duración de intervalos, amplitudes de onda o morfología del complejo QRS.

En esta línea, los métodos clásicos de aprendizaje automático han sido ampliamente utilizados. Un ejemplo de esto es el trabajo de Vimal y Sathish (Vimal y Sathish, 2010), donde se propone un sistema de clasificación de arritmias utilizando un modelo de Random Forest, basado en características extraídas manualmente del ECG. Se emplean técnicas como la variabilidad de la frecuencia cardíaca (HRV) y la transformada wavelet discreta (DWT) para generar características, obteniendo una alta capacidad de discriminación entre clases de arritmias.

Este tipo de enfoques dependen en gran medida de la calidad de las características extraídas, lo que puede limitar su capacidad de generalización en escenarios clínicos complejos o con variabilidad significativa en los registros electrocardiográficos.

Dentro de esta etapa de desarrollo de métodos clásicos, la disponibilidad de bases de datos de referencia es fundamental. La base de datos de MIT-BIH Arrhythmia Database (PhysioNet, 2005) se ha convertido en uno de los recursos más importantes en investigación sobre ECG.

La MIT-BIH Arrhythmia Database fue desarrollada conjuntamente por el Beth Israel Hospital de Boston y el MIT con el objetivo de proporcionar un conjunto estándar de señales ECG para la evaluación de algoritmos de detección de arritmias. Está compuesta por 48 registros de aproximadamente 30 minutos, obtenidos de pacientes ambulatorios, muestreados a 360 Hz y anotados por cardiólogos expertos, lo que la convierte en un estándar ampliamente utilizado en la validación de métodos automáticos.

Asimismo, la plataforma PhysioNet ha permitido el acceso a múltiples bases de datos biomédicas utilizadas en investigación. En particular, la base de datos utilizada en este trabajo proviene de este repositorio, lo que garantiza que los registros ECG empleados sean de referencia y ampliamente utilizados en la literatura científica

3.2. Inteligencia artificial aplicada al ECG

Con el avance del aprendizaje profundo, los modelos han evolucionado desde la dependencia de características manuales hasta sistemas capaces de aprender directamente del ECG.

Las redes neuronales convolucionales (CNN) han demostrado ser especialmente efectivas en el análisis de señales ECG, debido a su capacidad para capturar patrones locales y características morfológicas de la señal. En este contexto, Hannun et al. (Hannun et al., 2019) desarrollaron un modelo basado en deep neural networks para la clasificación de 12 tipos de ritmos cardíacos a partir de ECG ambulatorios de una sola derivación.

El modelo alcanza un área bajo la curva ROC de 0.97 y un F1-score de 0.837,

superando el rendimiento medio de cardiólogos expertos en la misma tarea. Estos resultados evidencian el potencial del aprendizaje profundo en la interpretación automática del ECG en escenarios clínicos reales. [igual esto no hace falta]

De forma complementaria, otros trabajos han explorado la aplicación de deep learning en patologías distintas a las arritmias. Un ejemplo de esto es estudio de Mayo Clinic (Wysokinski et al., 2024), donde se emplean redes neuronales profundas para la detección de embolia pulmonar a partir de ECG de 12 derivaciones. El modelo alcanza un área bajo la curva ROC de 0.69 para la detección de la embolia pulmonar aguda, mejorando hasta 0.84 en casos de embolia de alto riesgo. Los autores destacan el potencial clínico del modelo, especialmente por su alto valor predictivo negativo, lo que sugiere su utilidad para descartar casos graves de forma rápida.

El uso del ECG no se limita únicamente a clasificación, sino que también se ha explorado la predicción de eventos cardiovasculares, lo que refuerza el potencial del ECG como herramienta predictiva en medicina.

3.3. Líneas de investigación actuales

En la literatura reciente, el análisis automático del electrocardiograma ha evolucionado hacia líneas de investigación que buscan mejorar no solo la capacidad predictiva de los modelos, sino también su robustez, interpretabilidad y aplicabilidad en entornos clínicos reales. En este sentido, la inteligencia artificial está comenzando a integrarse progresivamente en sistemas de apoyo a la decisión médica, donde se combinan modelos de aprendizaje automático con validación clínica con el objetivo de facilitar su incorporación a la práctica hospitalaria. Aunque estos sistemas muestran resultados prometedores, su uso rutinario aún requiere validación adicional en entornos reales. (European Society of Cardiology, 2024)

Una línea de investigación relevante se centra en el estudio de cómo la información contenida en el electrocardiograma puede variar en función de las derivaciones utilizadas. En este contexto, Bergquist et al. (Bergquist et al., 2023) analizan la detección de disfunción ventricular izquierda utilizando modelos de aprendizaje automático entrenados con derivaciones individuales del ECG, comparándolos con modelos entrenados con las 12 derivaciones completas. Los resultados muestran que incluso con una sola derivación es posible obtener un rendimiento comparable, lo que sugiere que distintas partes del ECG pueden contener información relevante de forma independiente.

El uso de base de datos clínicos a gran escala ha permitido el desarrollo de modelos más robustos y generalizables. Se han utilizado registros de ECG combinados con información clínica adicional para entrenar sistemas de inteligencia artificial capaces de detectar múltiples condiciones cardiovasculares de forma simultánea.

En esta línea, el trabajo de Kalmady et al. (Kalmady et al., 2024) desarrolla y valida algoritmos de aprendizaje automático sobre más de 1.6 millones de ECG. En este estudio se plantean modelos capaces de predecir simultáneamente hasta 15 diagnósticos cardiovasculares diferentes, mostrando un rendimiento elevado en tareas de clasificación múltiple y destacando el potencial del ECG como herramienta de cribado poblacional a gran escala.

Otra línea de investigación relevante es el desarrollo de modelos interpretables de aprendizaje automático. En aplicaciones médicas, la explicabilidad de los modelos es un aspecto crítico, ya que permite aumentar la confianza del personal clínico en las predicciones realizadas por los sistemas automáticos. En este sentido, se han propuesto técnicas de interpretable machine learning aplicadas al análisis de ECG con el objetivo de mejorar la transparencia de los modelos y facilitar la comprensión de sus decisiones.

Ayano et al. (Ayano et al., 2022) realizan una revisión sistemática sobre técnicas de aprendizaje automático interpretables aplicadas al ECG, destacando que la falta de interpretabilidad sigue siendo una de las principales barreras para la adopción clínica de estos sistemas. Además, identifican la necesidad de desarrollar modelos más explicables que permitan justificar las decisiones en entornos médicos reales.

De forma complementaria, revisiones recientes han analizado el estado del arte del uso de inteligencia artificial en el ECG, destacando la transición desde métodos basados en ingeniería de características hacia arquitecturas profundas con extracción automática de patrones. Estas revisiones también subrayan problemas recurrentes como el desbalanceo de clases, la variabilidad inter-paciente y la falta de métricas de evaluación estandarizadas.

En este sentido, Prakash et al. (Prakash et al., 2025) revisan más de 100 estudios sobre clasificación de latidos ECG, señalando que, aunque los modelos actuales han alcanzado altos niveles de precisión, todavía existen desafíos importantes relacionados con la generalización y la validación clínica.

Finalmente, distintos centros de investigación han desarrollado líneas de trabajo centradas en la aplicación de machine learning al análisis del ECG para la detección de patologías cardiovasculares. En estos trabajos se destaca la importancia de factores como la selección de datos, la arquitectura del modelo y la validación externa, que influyen de manera determinante en el rendimiento final de los sistemas. (University of Utah - CEG, s.f.)

3.4. Limitaciones de los enfoques actuales

A pesar del avance de las técnicas de inteligencia artificial aplicadas al análisis del electrocardiograma, los enfoques propuestos en la literatura presentan todavía diversas limitaciones que condicionan su aplicabilidad en entornos clínicos reales

y su capacidad de generalización.

En primer lugar, una de las principales limitaciones reside en la simplificación del problema de clasificación. En numerosos trabajos, el diagnóstico de patologías cardiovasculares se plantea como un problema binario o como una clasificación multicategoría con un número reducido de clases. Sin embargo, esta formulación no refleja adecuadamente la complejidad del entorno clínico real, donde un mismo paciente puede presentar varias patologías simultáneamente. Esta simplificación facilita el entrenamiento de los modelos, pero reduce su capacidad para representar escenarios médicos más realistas.

Otro aspecto relevante es el uso limitado de la información disponible en las señales de electrocardiograma. En la literatura es frecuente encontrar estudios que utilizan únicamente un subconjunto reducido de derivaciones o representaciones simplificadas de la señal. Esta decisión puede implicar la pérdida de información espacial y temporal relevante, lo que afecta potencialmente a la capacidad diagnóstica de los modelos. Además, existe variabilidad entre trabajos en cuanto al número de derivaciones utilizadas y al tipo de señal considerada, lo que dificulta la comparación directa entre enfoques y limita la estandarización en el campo.

Relacionado con lo anterior, la representación de los datos constituye otro factor crítico. Algunos enfoques trabajan directamente con la señal ECG en bruto, mientras que otros dependen de la extracción previa de características manuales o estadísticamente diseñadas. Esta diversidad de estrategias implica que el rendimiento de los modelos puede depender fuertemente del tipo de preprocesado aplicado, sin que exista un consenso claro sobre cuál es la representación más adecuada. Esta falta de estandarización refleja una de las principales debilidades metodológicas del área.

Por otro lado, la mayoría de los enfoques existentes asumen una única etiqueta por muestra, lo que implica tratar el problema como una clasificación de clase única. Esta aproximación simplifica considerablemente el diseño del modelo, pero no se ajusta completamente a la realidad clínica, en la que es frecuente la coexistencia de múltiples patologías en un mismo paciente. En este sentido, la ausencia de formulaciones multilabel en gran parte de la literatura limita la capacidad de los sistemas actuales para representar escenarios médicos complejos.

En cuanto a la evaluación de los modelos, es habitual el uso de métricas globales como accuracy, F1-score o AUC. Sin embargo, estas métricas no siempre reflejan adecuadamente el impacto clínico de los errores cometidos, especialmente en escenarios con clases desbalanceadas. En muchos casos, la evaluación se realiza en condiciones controladas que no permiten analizar con suficiente detalle el comportamiento del modelo en situaciones clínicas reales.

El desbalanceo de clases constituye, además, otra limitación importante. Los conjuntos de datos utilizados en este tipo de problemas suelen presentar una dis-

tribución desigual de las patologías, con una clara predominancia de las clases más frecuentes. Esto provoca que los modelos tiendan a favorecer dichas clases mayoritarias, afectando especialmente al rendimiento en la detección de enfermedades menos representadas. Aunque existen técnicas para mitigar este problema, su aplicación no es homogénea en la literatura.

Finalmente, la interpretabilidad de los modelos representa una barrera fundamental para su adopción clínica. Muchos de los enfoques basados en aprendizaje profundo funcionan como modelos de tipo “caja negra”, lo que dificulta la comprensión de las decisiones que generan. Esta falta de explicabilidad reduce la confianza de los profesionales sanitarios en los sistemas automáticos y limita su integración en la práctica médica. Aunque existen líneas de investigación orientadas al desarrollo de modelos más interpretables, todavía existe un compromiso claro entre rendimiento y capacidad de explicación.

En conjunto, todas estas limitaciones evidencian que, a pesar del alto rendimiento alcanzado por los modelos actuales en entornos experimentales, todavía existen importantes retos abiertos en cuanto a la representación del problema, la calidad y utilización de los datos, la evaluación de los sistemas y su aplicabilidad clínica. Estas limitaciones justifican la necesidad de desarrollar enfoques más completos, capaces de abordar el problema desde una perspectiva más realista y alineada con la práctica médica.

Capítulo 4

Definición del Trabajo

4.1. Justificación del proyecto

A partir de las limitaciones analizadas en el estado del arte, el presente trabajo plantea un análisis comparativo de distintos escenarios de clasificación de señales ECG, evaluando el impacto que tienen distintos factores sobre el rendimiento de los modelos de aprendizaje automático. Se analiza la influencia del número de derivaciones utilizadas, comparando los resultados obtenidos con una sola derivación frente a los obtenidos utilizando el ECG completo de 12 derivaciones. Del mismo modo, se comparan distintas formas de representar la información, desde la señal ECG en bruto hasta la extracción de características manuales o estadísticas, con el objetivo de evaluar su impacto en el rendimiento de los modelos.

El trabajo utiliza distintos enfoques del problema de clasificación. Se considera un enfoque binario que detecta grupos generales de patologías y otro enfoque más complejo basado en múltiples enfermedades y salidas probabilísticas. Permite analizar escenarios más próximos a la realidad clínica, donde un mismo registro puede presentar varias alteraciones simultáneamente y donde el nivel de confianza asociado a cada predicción puede resultar relevante desde el punto de vista médico.

Además, el trabajo no se limita únicamente al estudio del rendimiento global de los modelos, sino que también analiza el comportamiento de distintas métricas de evaluación adaptadas a problemas con clases desbalanceadas y escenarios multilabel. De esta forma, se busca obtener una evaluación más representativa del comportamiento real de los clasificadores en tareas de diagnóstico automático.

En conjunto, el objetivo del trabajo es estudiar distintas estrategias de clasificación sobre registros electrocardiográficos reales, analizando las ventajas y limitaciones de cada configuración experimental y explorando enfoques más flexibles y representativos de situaciones clínicas reales.

4.2. Base de datos utilizada

Para el desarrollo del presente trabajo se ha utilizado una base de datos de registros electrocardiográficos ampliamente utilizada en investigación biomédica. La selección de una base de datos adecuada resulta especialmente relevante en problemas de clasificación automática de ECG, ya que las características de los registros, el etiquetado clínico y la diversidad de patologías condicionan de forma directa el rendimiento y la capacidad de generalización de los modelos desarrollados.

En este trabajo se emplea la base de datos PTB-XL, disponible públicamente a través de la plataforma PhysioNet. (Wagner et al., 2022) Esta base de datos ha sido diseñada específicamente para facilitar tareas de investigación relacionadas con el análisis automático de señales ECG y el desarrollo de modelos de aprendizaje automático aplicados al diagnóstico cardiovascular.

4.2.1. Origen del dataset

La base de datos PTB-XL fue desarrollada con el objetivo de proporcionar un conjunto de datos electrocardiográficos de gran tamaño y alta calidad, que permita el entrenamiento y la evaluación de modelos de inteligencia artificial en tareas de clasificación de patologías cardíacas.

El dataset cuenta con más de 21000 registros de ECG de 12 derivaciones, obtenidos de aproximadamente 19000 pacientes diferentes. Proceden de práctica clínica real, y fueron anotados por especialistas médicos, lo que garantiza la calidad y relevancia de las etiquetas asociadas a cada registro.

4.2.2. Estructura del dataset

Cada registro de la base de datos corresponde a un ECG de 12 derivaciones con una duración aproximada de 10 segundos. Las señales incluyen las derivaciones estándar (I, II, III, aVR, aVL, aVF) y las precordiales (V1-V6).

Los registros se encuentran almacenados en formato WFDB, muy utilizado en bases de datos biomédicas y compatible con herramientas de procesamiento de señales ECG en Python. Además de las señales electrocardiográficas, el dataset incorpora información adicional asociada a cada registro, incluyendo identificadores de paciente, características demográficas y anotaciones diagnósticas.

PTB-XL proporciona dos versiones de las señales ECG con distintas frecuencias de muestreo: una versión de 100 Hz y otra de 500 Hz. Esta característica permite adaptar el procesamiento de las señales a distintos tipos de aplicaciones y modelos de aprendizaje automático. En este trabajo se ha utilizado la versión de 500 Hz, ya que proporciona una mayor resolución temporal, lo que puede ser beneficioso para la detección de patrones sutiles en la señal ECG. Es por esto que la señal

se presenta como una matriz de 12 x 5000, donde las 12 filas corresponden a las derivaciones y las 5000 columnas representan las muestras de la señal a lo largo del tiempo.

La estructura del dataset permite trabajar tanto con las señales originales completas como con características extraídas posteriormente mediante técnicas de procesamiento y análisis de señal.

4.2.3. Etiquetado original

El sistema de etiquetado de la base de datos se basa en un enfoque multilabel, en el que cada registro electrocardiográfico puede estar asociado simultáneamente a múltiples patologías. A diferencia de un esquema de clasificación convencional con una única clase por muestra, este tipo de anotación permite representar escenarios clínicos más realistas, en los que pueden coexistir distintas alteraciones cardíacas en un mismo paciente.

En este trabajo, las etiquetas se encuentran estructuradas en forma de diccionario, donde cada clave corresponde a una de las 71 patologías consideradas en la base de datos. El valor asociado a cada clave representa una probabilidad (expresada en escala de 0 a 100) que indica el grado de presencia o compatibilidad de dicha patología en el registro ECG correspondiente.

Esta representación transforma el problema en un escenario de clasificación multilabel con salidas probabilísticas, lo que permite desarrollar modelos capaces de predecir no solo la presencia o ausencia de cada patología, sino también el nivel de confianza asociado a cada predicción.

A partir de este etiquetado original, el trabajo plantea posteriormente distintos escenarios de clasificación, incluyendo formulaciones binarias y agrupaciones de patologías en clases más generales, con el objetivo de analizar el comportamiento de los modelos bajo diferentes niveles de complejidad.

4.2.4. Problemas del dataset

A pesar de tratarse de una base de datos ampliamente utilizada en investigación y de gran valor para el desarrollo de modelos de aprendizaje automático, el conjunto de datos presenta diversas limitaciones que condicionan el diseño de los modelos y la interpretación de los resultados.

En primer lugar, se observa un desbalanceo significativo entre patologías. Algunas enfermedades aparecen con una frecuencia elevada dentro del conjunto de registros, mientras que otras están representadas por un número reducido de casos. Esta distribución desigual puede influir en el proceso de aprendizaje, favoreciendo la detección de las clases mayoritarias y dificultando la identificación de patologías menos representadas.

En segundo lugar, la propia naturaleza del etiquetado introduce complejidad adicional. Al tratarse de un sistema multilabel probabilístico, en el que cada patología se asocia a un valor de probabilidad entre 0 y 100, existe una dependencia directa del criterio del umbral que se utilice posteriormente para transformar estas probabilidades en decisiones discretas. Este aspecto puede afectar de forma relevante al rendimiento final del sistema.

Otro factor importante es la coexistencia de múltiples patologías en un mismo registro, lo que incrementa la complejidad del problema respecto a enfoques de clasificación tradicional. Esta situación refleja mejor la realidad clínica, pero dificulta el aprendizaje de fronteras de decisión claras entre clases.

Además, la variabilidad intrínseca de las señales electrocardiográficas, derivada de diferencias entre pacientes, condiciones de adquisición y posibles artefactos en la señal, introduce ruido que puede afectar a la robustez de los modelos.

Finalmente, aunque la base de datos es un referente en el ámbito del análisis automático de ECG, los modelos entrenados sobre este conjunto pueden no generalizar de forma directa a otros entornos clínicos o poblaciones distintas, lo que pone de manifiesto la necesidad de validaciones adicionales en escenarios externos.

4.3. Agrupación de patologías

La base de datos utilizada en este trabajo contiene un total de 71 patologías diferentes, definidas mediante el sistema de anotación SCP-ECG. Este nivel de precisión introduce una elevada complejidad en el problema de clasificación, especialmente en escenarios multilabel y con distribución desbalanceada de clases.

Con el objetivo de simplificar el problema y estructurar el análisis, en este trabajo se emplea una agrupación de las patologías en cinco superclases clínicas generales, previamente definidas en el apartado 2.3. Esta agrupación permite reducir la complejidad del espacio de salida y facilita la interpretación de los resultados obtenidos por los modelos.

Este enfoque permite trabajar simultáneamente con dos niveles de análisis: por un lado, el nivel detallado basado en las 71 patologías originales, y por otro, un nivel más general basado en las cinco superclases. Esta dualidad resulta especialmente útil para evaluar el impacto del nivel de detalle en el rendimiento de los modelos de clasificación.

Además, esta estructura facilita la definición de distintos escenarios experimentales, permitiendo comparar el comportamiento de los modelos bajo formulaciones más complejas frente a aproximaciones más simplificadas.

4.4. Escenarios experimentales

Con el objetivo de analizar el impacto de distintos factores en el rendimiento de los modelos de clasificación automática de ECG, se plantean tres enfoques experimentales diferentes, que varían en función del número de derivaciones utilizadas, el nivel de detalle en la representación de las patologías y el tipo de salida generada por el modelo.

4.4.1. Configuración 1: señal reducida y clasificación binaria

En este primer escenario plantea un enfoque simplificado, en el que se utiliza únicamente la derivación I del ECG, y se agrupan las patologías en las cinco superclases definidas previamente. El objetivo de esta configuración es evaluar el rendimiento de los modelos en condiciones de información reducida, simulando escenarios en los que solo se dispone de dispositivos de monitorización con capacidad limitada.

Este modelo se entrena para realizar una clasificación binaria, en la que el objetivo es detectar la presencia o ausencia de cada una de las cinco superclases de patologías.

Esta configuración se entrenará tanto con la señal ECG en bruto como con características extraídas, lo que permitirá analizar el impacto de la representación de los datos en el rendimiento del modelo.

4.4.2. Configuración 2: señal completa y clasificación binaria

En el segundo escenario se utiliza la señal completa de 12 derivaciones pero manteniendo la misma agrupación de patologías en cinco superclases.

De esta forma, este escenario permite aislar el efecto del aumento en la información de entrada, manteniendo constante la complejidad del problema de clasificación.

En este caso, debido a la enorme cantidad de datos, el modelo se entrenará únicamente con las características extraídas de la señal, lo que permitirá evaluar el impacto de la representación de los datos en un escenario con información completa.

4.4.3. Configuración 3: señal completa y clasificación multi-label probabilística

En este tercer escenario se plantea el enfoque más complejo, en el que se utiliza la señal completa de 12 derivaciones y se trabaja con las 71 patologías originales,

sin realizar agrupaciones.

Además, en este caso se mantiene la naturaleza multilabel y probabilística del etiquetado original, lo que implica que el modelo debe ser capaz de predecir simultáneamente la presencia o ausencia de cada patología, así como el nivel de confianza asociado a cada predicción.

Este escenario permite evaluar el comportamiento de los modelos en condiciones lo más cercanas posible a la complejidad clínica real, donde pueden coexistir múltiples patologías simultáneamente y donde la salida no se limita a una decisión binaria.

Al igual que en el escenario anterior, debido a la gran cantidad de datos y la complejidad del problema, el modelo se entrenará únicamente con características extraídas de la señal ECG.

4.5. Objetivos técnicos

A partir de los escenarios experimentales definidos anteriormente, este trabajo plantea una serie de objetivos técnicos orientados a analizar el impacto de diferentes decisiones de modelado en el rendimiento de los sistemas de clasificación de señales electrocardiográficas.

En primer lugar, se estudia el efecto del número de derivaciones utilizadas en la entrada del modelo. Se compara el rendimiento obtenido al emplear una única derivación frente al uso completo de las 12 derivaciones disponibles, con el objetivo de evaluar hasta qué punto la información espacial del electrocardiograma influye en la capacidad de discriminación de las distintas patologías.

En segundo lugar, se analiza la influencia de la formulación del problema de clasificación. En particular, se comparan enfoques binarios basados en la detección simplificada de presencia o ausencia de patología con un enfoque multilabel probabilístico, en el que cada salida del modelo representa la probabilidad de pertenencia a una determinada clase.

Otro objetivo consiste en el análisis del nivel de detalle considerado en las etiquetas. Para ello, se contraponen escenarios basados en un conjunto reducido de 5 clases frente al uso completo de 71 patologías. Esta comparación permite evaluar cómo afecta la complejidad del espacio de salida al rendimiento global del modelo.

Por otro lado, se aborda la transformación de las probabilidades asociadas a las etiquetas en decisiones discretas en los escenarios binarios. Para ello, se emplean umbrales óptimos, determinados de forma empírica con el objetivo de maximizar el rendimiento del modelo en cada caso. El análisis de estos umbrales resulta clave para equilibrar la sensibilidad frente a distintas clases y mejorar la capacidad de generalización.

Finalmente, se pretende estudiar la interacción entre todos estos factores, evaluando cómo la combinación de la representación de la señal, la formulación del problema y la estructura de las etiquetas condiciona el comportamiento de los modelos de clasificación automática de ECG.

4.6. Metodología general

A partir de los escenarios experimentales y objetivos definidos anteriormente, se presenta a continuación la metodología general empleada en este trabajo, que integra el procesamiento de los datos, el diseño de los modelos y la evaluación de los resultados.

Cada registro de la base de datos es una matriz de 12 x 5000, donde las filas corresponden a las derivaciones del ECG y las columnas representan las muestras de la señal a lo largo del tiempo. También incluye información demográfica como la edad y el sexo del paciente, así como un sistema de etiquetado basado en un diccionario que asocia cada patología a una probabilidad de presencia. En función del escenario experimental considerado, se ha transformado la etiqueta original para adaptarla a cada caso.

Antes de comenzar con la limpieza y preprocesado de las señales se eliminaron todos los registros de aquellos pacientes con menos de 18 años y más de 89, con el objetivo de enfocar el análisis en la población adulta.

Posteriormente, las señales pasan por un proceso de preprocesado con el objetivo de detectar los ciclos cardíacos principales, identificando los picos R como referencia dentro del ECG. A partir de esta información, se eliminan los registros que contienen menos de 10 latidos, y de los restantes se seleccionan únicamente los 10 primeros latidos para cada paciente. Se segmenta la señal en latidos individuales, lo que permite estructurar los datos de forma homogénea.

A partir de esta representación, se consideran distintas formas de entrada para los modelos. En un primer enfoque, se construye un megavector concatenando los latidos de cada paciente, de manera que el modelo pueda analizar la señal completa de forma global. En un segundo enfoque, se extraen características temporales, morfológicas y estadísticas de cada latido, con el objetivo de proporcionar a los modelos una representación más compacta y representativa de la señal.

Una vez preparados los datos, se procede al entrenamiento de los distintos modelos de aprendizaje automático definidos en el estudio, evaluando su comportamiento bajo las diferentes configuraciones experimentales.

Finalmente, la evaluación de los resultados se realiza mediante métricas adecuadas a cada escenario experimental, permitiendo comparar de forma consistente el rendimiento de los modelos. Adicionalmente, se ha desarrollado una herramienta de visualización tipo dashboard con el objetivo de facilitar el análisis de los

resultados obtenidos. Esta herramienta permite explorar las predicciones de los modelos y la información asociada a los registros electrocardiográficos de forma más intuitiva, contribuyendo a la interpretación global del comportamiento del sistema.

Capítulo 5

Modelo Desarrollado

En este capítulo se describe la estructura del sistema desarrollado para el análisis automático de señales electrocardiográficas. Se detallan los distintos bloques que componen el pipeline de procesamiento, desde la entrada de los datos hasta la obtención de las predicciones finales.

Además, se presentan las principales etapas de análisis de los datos, así como los procesos de preprocesado y transformación de las señales ECG utilizados como base para los modelos de aprendizaje automático.

Finalmente, se describen los distintos enfoques experimentales planteados y la metodología seguida para el desarrollo y evaluación de los modelos, con el objetivo de analizar el impacto de las distintas configuraciones propuestas.

5.1. Arquitectura general del sistema

El sistema desarrollado en este trabajo se basa en un pipeline de aprendizaje automático aplicado al análisis de señales ECG, cuyo objetivo es la detección y clasificación automática de patologías cardíacas a partir de registros electrocardiográficos.

Está compuesto por varias etapas secuenciales que permiten transformar la señal original en predicciones clínicas relevantes. El flujo completo empieza con la entrada de los registros electrocardiográficos, junto con la información asociada a cada paciente, y las etiquetas diagnósticas correspondientes.

A continuación, las señales pasan por una etapa de preprocesado, donde los datos se limpian y se preparan con el objetivo de mejorar la representación para el posterior análisis. Esta fase permite homogeneizar los registros y eliminar posibles problemas derivados de la variabilidad intrínseca de las señales ECG.

Posteriormente, los datos procesados son transformados para su utilización en los modelos de aprendizaje automático. Dependiendo del escenario experimental

considerado, esta transformación puede realizarse mediante un megavector que concatena los latidos de cada paciente o mediante la extracción de características representativas de la señal ECG.

Una vez obtenida la representación adecuada de los datos, se procede al entrenamiento de los modelos de aprendizaje automático definidos en el estudio, evaluando su rendimiento bajo las distintas configuraciones experimentales planteadas. La salida del sistema puede representarse de forma binaria o probabilística, dependiendo del enfoque utilizado en cada caso.

Finalmente, las predicciones obtenidas son evaluadas mediante distintas métricas de rendimiento, permitiendo comparar el comportamiento de los modelos en los diferentes escenarios planteados.

En la Figura 5.1 se muestra un diagrama general del pipeline de procesamiento desarrollado en este trabajo, que ilustra las distintas etapas y su interconexión dentro del sistema global.




Figura 5.1: Pipeline general del sistema. Elaboración propia.

5.2. Análisis exploratorio de datos

En este apartado se realiza un análisis exploratorio de los datos de la bases de datos utilizada, con el objetivo de comprender la estructura del conjunto utilizado, así como las características demográficas de la población estudiada. Este análisis permite contextualizar los datos antes de su utilización en los modelos de aprendizaje automático y detectar posibles patrones relevantes o desbalances en la población.

En primer lugar, se analiza la distribución de los pacientes por edad en el conjunto de datos. La Figura 5.2 muestra el histograma de edades correspondiente, que revela una distribución relativamente equilibrada entre los distintos grupos de edad, con una ligera predominancia de pacientes en el rango de 50 a 70 años, lo que es consistente con la prevalencia de patologías cardiovasculares en la población adulta. Como se ha mencionado anteriormente, se han eliminado los registros de

pacientes menores de 18 años y mayores de 89 años, por lo que en el gráfico solo se muestran los pacientes comprendidos en este rango de edad.

[cambiar colores de graficas?]




Figura 5.2: Distribución de los pacientes por edad

A continuación, se analiza la distribución de los pacientes por sexo. La Figura 5.3 muestra que existe una ligera predominancia de pacientes masculinos en el conjunto de datos, con aproximadamente un 55 % de hombres frente a un 45 % de mujeres. Esta distribución es coherente con la epidemiología de las enfermedades cardiovasculares, que suelen presentar una mayor prevalencia en hombres (Salvavidas, 2025), aunque también es importante destacar la presencia significativa de mujeres en el conjunto de datos, lo que permite desarrollar modelos que puedan generalizar a ambos sexos. El 0 en el gráfico corresponde a pacientes masculinos y el 1 a pacientes femeninos.




Figura 5.3: Distribución de los pacientes por sexo

De forma complementaria, se analiza la relación entre edad y sexo, con el fin de obtener una visión más detallada de la composición de la población. Este

análisis permite observar cómo se distribuyen ambas variables de forma conjunta y si existen diferencias relevantes entre grupos. La Figura 5.4 representa esta relación mediante una visualización combinada de ambas variables.




Figura 5.4: Distribución de los pacientes por edad y sexo

En conjunto, este análisis proporciona una visión general de la estructura demográfica del conjunto de datos, lo cual resulta fundamental para interpretar adecuadamente los resultados obtenidos en las etapas posteriores del estudio.

Una vez analizada la distribución demográfica del conjunto de datos, se estudia la distribución de las etiquetas diagnósticas con el objetivo de evaluar el balance entre las distintas patologías presentes en el estudio.

En primer lugar, se analiza la distribución de las clases originales del conjunto de datos. La Figura 5.5 muestra la frecuencia de aparición de cada una de las patologías consideradas. Como puede observarse, existe un claro desbalance entre clases, con un reducido número de patologías muy representadas frente a un gran número de clases con baja frecuencia de aparición.

[pongo este gráfico? No se ve nada, no se distingue nada, no aporta nada, es un gráfico de barras con 71 clases]




Figura 5.5: Distribución de las patologías en el conjunto de datos.

Dado el elevado número de categorías (71 patologías), se presenta adicionalmente una visualización alternativa basada en las 10 clases más frecuentes, agrupando el resto en una categoría adicional. Esta representación, mostrada en la Figura 5.6, permite observar de forma más clara las patologías predominantes en el conjunto de datos y facilita la interpretación del desbalance existente.




Figura 5.6: Distribución de las patologías más frecuentes en el conjunto de datos.

Además, se analiza la distribución del conjunto de datos en función de las superclases en las que se agrupan las patologías. La Figura 5.7 muestra esta agrupación, en la que se observa una reducción de la especificidad del problema original, permitiendo una visión más general del tipo de patologías presentes en el dataset.




Figura 5.7: Distribución de las patologías por superclases.

En conjunto, este análisis evidencia la existencia de un importante desbalance en las etiquetas, tanto a nivel de clases individuales como en su agrupación por su-

perclases, lo cual constituye un aspecto relevante a tener en cuenta en el desarrollo de los modelos de clasificación.

Cabe destacar que, en todos los casos analizados, la clase "NORM", correspondiente a registros electrocardiográficos normales, se mantiene como la clase mayoritaria. Esta predominancia es consistente tanto en la distribución de clases individuales como en las representaciones agrupadas, lo que refuerza el carácter desbalanceado del conjunto de datos y la importancia de considerar este efecto en el diseño y evaluación de los modelos.

Por otro lado, se analiza la coexistencia de patologías mediante una matriz de co-ocurrencia entre las 20 clases más frecuentes, ya que representar las 71 enfermedades dificulta la interpretación visual.




Figura 5.8: Matriz de co-ocurrencia de las 20 clases más frecuentes.

En la Figura 5.8 se observa que existen ciertas patologías que tienden a coexistir con mayor frecuencia. Destaca especialmente la relación entre infartos como IMI (infarto inferior), ASMI (infarto anteroseptal) y ALMI (infarto lateral alto) con alteraciones de conducción como LAFB (bloqueo fascicular anterior izquierdo), CRBBB (bloqueo de rama derecha completo) e IRBBB (bloqueo de rama derecha incompleto). Estas asociaciones reflejan la frecuente coexistencia entre alteraciones estructurales del corazón y trastornos del sistema de conducción.

De igual forma, se observan co-ocurrencias relevantes entre patologías isquémicas como ISC_ (isquemia general), ISCAL (isquemia anterolateral) e ISCLN

(isquemia inferior) y eventos como IMI, lo que pone de manifiesto la superposición de manifestaciones electrocardiográficas en distintos estadios de enfermedad coronaria.

[poner en negrita las enfermedades?]

Por otro lado, patologías como LVH (hipertrofia ventricular izquierda) presentan múltiples asociaciones con distintas clases, especialmente con ISC_ y con alteraciones de conducción como IVCD (trastorno inespecífico de conducción intraventricular), lo que sugiere su papel como condición frecuentemente concomitante dentro del conjunto de datos.

También se identifican combinaciones poco frecuentes entre determinadas patologías, especialmente en el caso de arritmias aisladas, lo que refleja la heterogeneidad del dataset y el marcado desbalance entre clases.

Estos factores justifican la necesidad de enfoques de modelado capaces de manejar múltiples etiquetas y capturar relaciones entre clases, aspectos que se abordarán en las siguientes secciones del trabajo.

Además de analizar la frecuencia individual de cada patología, es interesante analizar cuantas patologías diferentes aparecen asociadas a un mismo registro ECG. Este análisis permite evaluar la complejidad de la base de datos y calcular la frecuencia con la que varias alteraciones cardíacas coexisten en un mismo paciente.

Como se observa en la Figura 5.9, la mayoría de los registros presentan una o ninguna patología asociada, lo que indica una predominancia de electrocardiogramas normales. Sin embargo, también existe una proporción significativa de registros que presentan múltiples patologías simultáneamente, lo que refleja la complejidad clínica del conjunto de datos y la necesidad de desarrollar modelos capaces de manejar escenarios multilabel en los que coexisten múltiples alteraciones.




Figura 5.9: Distribución del número de patologías por paciente.

Para la elaboración de este gráfico se ha considerado que un paciente tuviese 0 patologías si como único elemento en la etiqueta fuese de la categoría “NORM” con una probabilidad mayor que 0, mientras que si presentaban esta categoría y otra más con una probabilidad mayor que 0 se consideraba que el paciente presentaba 1 patología, y así sucesivamente. [\[revisar redacción\]](#)

5.3. Preprocesado de datos

Limpieza, picos R, transformadas

5.4. Selección y extracción de características

Justificar porque se han seleccionado esas características

5.5. Desarrollo experimental y optimización del sistema

Hablar aqui de todo: los modelos que he usado, los tres enfoques distintos

Capítulo 6

Análisis de Resultados

Resultados globales, comparacion entre enfoques, resultados por enfermedad (matrices de confusion), thresholds personalizados, analisis clinicos, limitaciones

Capítulo 7

Conclusiones y Trabajos Futuros

Conclusiones y posibles mejoras y trabajos futuros

Bibliografía

- Amit, H. (2024). Evaluation metrics for classification models [Accedido: 2026-04-24]. <https://medium.com/biased-algorithms/evaluation-metrics-for-classification-models-b995f9980716>
- Ayano, Y. M., Schwenker, F., Dufera, B. D., & Debelee, T. G. (2022). Interpretable Machine Learning Techniques in ECG-Based Heart Disease Classification: A Systematic Review [Accedido: 2026-04-17]. *Diagnostics (Basel)*, 13(1), 111. <https://doi.org/10.3390/diagnostics13010111>
- Bergquist, J. A., Zenger, B., Brundage, J., MacLeod, R. S., Shah, R., Ye, X., Lyones, A., Ranjan, R., Tasdizen, T., Bunch, T. J., & Steinberg, B. A. (2023). Comparison of Machine Learning Detection of Low Left Ventricular Ejection Fraction Using Individual ECG Leads [Accedido: 2026-04-17]. *Computing in Cardiology*, 50, 1. <https://doi.org/10.22489/CinC.2023.047>
- Buhl, N. (2023). F1 Score in Machine Learning [Accedido: 2026-04-24]. <https://encord.com/blog/f1-score-in-machine-learning/>
- Cigna. (s.f.). El corazón y su sistema eléctrico [Accedido: 2026-01-15]. <https://www.cigna.com/es-us/knowledge-center/hw/el-corazn-y-su-sistema-electrico-zm2272>
- Eje cardíaco en el ECG: cálculo e interpretación [Accedido: 2026-04-10]. (2026). <https://www.cardioteca.com/imagen/8008-eje-cardiaco-ecg-calculo.html>
- European Society of Cardiology. (2024). Artificial intelligence in ECG diagnostics - where are we now? [Accedido: 2026-04-17]. <https://www.escardio.org/communities/councils/cardiology-practice/education/cardiopractice/artificial-intelligence-in-ecg-diagnostics-where-are-we-now/>
- Evidently AI. (2025). Accuracy, precision, recall and related classification metrics [Accedido: 2026-04-24]. <https://www.evidentlyai.com/classification-metrics/accuracy-precision-recall>
- Hannun, A. Y., Rajpurkar, P., Haghpanahi, M., Tison, G. H., Bourn, C., Turakhia, M. P., & Ng, A. Y. (2019). Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network [Accedido: 2026-04-17]. *Nature Medicine*, 25(1), 65-69. <https://doi.org/10.1038/s41591-018-0268-3>

- Kalmady, S. V., Salimi, A., Sun, W., Sepehrvand, N., Nademi, Y., Bainey, K., Ezekowitz, J., Hindle, A., McAlister, F., Greiner, R., Sandhu, R., & Kaul, P. (2024). Development and validation of machine learning algorithms based on electrocardiograms for cardiovascular diagnoses at the population level [Accedido: 2026-04-17]. *npj Digital Medicine*, 7, 133. <https://doi.org/10.1038/s41746-024-01133-?>
- Klabunde, Richard E. (2023). Electrocardiogram Leads [Accedido: 2025-11-07]. <https://cvphysiology.com/arrhythmias/a013>
- MedlinePlus. (s.f.). Electrocardiograma [Accedido: 2025-11-06]. <https://medlineplus.gov/spanish/pruebas-de-laboratorio/electrocardiograma/>
- Murel, J., & Kavlakoglu, E. (s.f.). ¿Qué es una matriz de confusión? [Accedido: 2026-04-24]. <https://www.ibm.com/es-es/think/topics/confusion-matrix>
- My-EKG. (s.f.-a). Derivaciones cardíacas [Accedido: 2025-11-07]. <https://www.my-ekg.com/generalidades-ekg/derivaciones-cardiacas.php>
- My-EKG. (s.f.-b). Dilatación de aurícula izquierda [Accedido: 2025-11-07]. <https://www.my-ekg.com/hipertrofia-dilatacion/dilatacion-auricula-izquierda.php>
- PhysioNet. (2005). MIT-BIH Arrhythmia Database [Dataset disponible en PhysioNet. Accedido: 2026-04-17]. <https://physionet.org/content/mitdb/1.0.0/>
- Prakash, A. J., Belkacem, A. N., Elfadel, I. M., Jelinek, H. F., & Atef, M. (2025). Advances in machine and deep learning for ECG beat classification: a systematic review [Accedido: 2026-04-17]. *Frontiers in Digital Health*, 7. <https://doi.org/10.3389/fdgth.2025.1649923>
- Prutkin, J. M., Goldberger, A. L., & Botkin, N. F. (2025). ECG tutorial: Basic principles of ECG analysis [Topic 2115, Version 36.0. Accedido: 2025-11-21].
- Repsol. (2026). Machine Learning: innovación y aplicaciones [Accedido: 2026-04-24]. <https://www.repsol.com/es/energia-avanzar/innovacion/machine-learning/index.cshtml>
- Salvavidas. (2025). Diferencias de género en enfermedades cardíacas [Accedido: 2026-05-24]. <https://salvavidas.com/blog/diferencias-de-genero-en-enfermedades-cardiacas/>
- Sociedad Argentina de Cardiología (SADEC). (s.f.). El sistema eléctrico del corazón y qué es una arritmia [Accedido: 2026-01-15]. <https://www.sociedadesadec.org.ar/el-sistema-electrico-del-corazon-que-es-una-arritmia/>
- Stanford Children's Health. (s.f.-a). Anatomy and Function of the Electrical System [Accedido: 2026-01-15]. <https://www.stanfordchildrens.org/es/topic/default?id=anatomy-and-function-of-the-electrical-system-90-P04865>
- Stanford Children's Health. (s.f.-b). Anatomy and Function of the Heart's Electrical System [Accedido: 2026-01-15]. <https://www.stanfordchildrens.org/es/topic/default?id=anatomy-and-function-of-the-hearts-electrical-system-85-P03337>

- University of Utah - CEG. (s.f.). Machine Learning Research Area [Accedido: 2026-04-17]. <https://ceg.sci.utah.edu/research-areas/machine-learning/>
- Vimal, C., & Sathish, B. (2010). Random Forest Classifier Based ECG Arrhythmia Classification [Accedido: 2026-04-17]. *International Journal of E-Health and Medical Communications (IGI Global)*. <https://www.igi-global.com/article/random-forest-classifier-based-ecg/42992>
- Wagner, P., Strodthoff, N., Bousseljot, R.-D., Samek, W., & Schaeffter, T. (2022). PTB-XL, a large publicly available electrocardiography dataset (version 1.0.3). <https://doi.org/10.13026/kfzx-aw45>
- Wysokinski, W. E., Meverden, R. A., Lopez-Jimenez, F., Harmon, D. M., Medina Inojosa, B. J., Baez Suarez, A., Liu, K., Medina Inojosa, J. R., Casanegra, A. I., McBane, R. D., & Houghton, D. E. (2024). Electrocardiogram Signal Analysis With a Machine Learning Model Predicts the Presence of Pulmonary Embolism With Accuracy Dependent on Embolism Burden [Accedido: 2026-04-17]. *Mayo Clinic Proceedings: Digital Health*, 2(3), 453-462. <https://doi.org/10.1016/j.mcpdig.2024.03.009>